

Atividade de Iniciação Científica

- **Tema:** Predição de Capacidade de Armazenamento (*Capacity Planning*) usando Regressão Linear Simples
- **Área:** Análise e Desenvolvimento de Sistemas / Infraestrutura de TI
- **Dataset:** monitoramento_disco_10k_v2.csv (10.000 observações diárias)

1. Contexto do Problema

Em ambientes de produção, servidores de banco de dados e aplicações geram logs, arquivos temporários e novos registros continuamente. O esgotamento do espaço em disco (100% de uso) causa falhas graves e indisponibilidade de serviços (*downtime*).

Para evitar interrupções não planejadas, a equipe de Infraestrutura e TI precisa prever a data estimada de esgotamento da capacidade do servidor. Essa prática, conhecida como *Capacity Planning* (Planejamento de Capacidade), permite dimensionar compras de hardware ou programar rotinas de expurgo com a devida antecedência.

Você recebeu o arquivo `monitoramento_disco_10k_v2.csv`, que contém 10.000 medições diárias consecutivas da ocupação do disco rígido de um servidor crítico.

- Colunas do dataset:
 - `dia`: Dia sequencial de monitoramento ($x = 1, 2, 3, \dots, 10000$).
 - `uso_disco_gb`: Ocupação total do disco em Gigabytes (y).

2. Objetivos e Atividades

Desenvolva um relatório de análise contendo as seguintes etapas (utilizar Python):

Etapa 1: Análise Exploratória de Dados

1. Importe o dataset e apresente a tabela com as principais estatísticas descritivas das variáveis `dia` e `uso_disco_gb` (Média, Desvio Padrão, Mínimo, Mediana e Máximo).
2. Construa um gráfico de dispersão (*scatterplot*) de `uso_disco_gb` em função do `dia`.

3. Descreva o comportamento visual observado: a tendência geral é linear? Existe variação/ruído em torno dessa tendência?

Etapla 2: Ajuste do Modelo Estatístico

1. Ajuste um modelo de Regressão Linear Simples:

$$\hat{y} = \beta_0 + \beta_1 x$$

2. Apresente a equação resultante com os valores estimados para o intercepto ($\hat{\beta}_0$) e para o coeficiente angular ($\hat{\beta}_1$).
3. Interpretação prática: Explique o significado operacional dos coeficientes $\hat{\beta}_0$ e $\hat{\beta}_1$ no contexto de monitoramento do servidor.

Etapla 3: Avaliação do Ajuste e Resíduos

1. Calcule o Coeficiente de Determinação (R^2) e a Raiz do Erro Quadrático Médio (RMSE).
2. O que a porcentagem complementar do R^2 restantes da variância representam no dia a dia da infraestrutura de TI?
3. Plote o gráfico da linha de regressão ajustada sobreposta aos dados reais de dispersão.

Etapla 4: Predição e Tomada de Decisão Tecnológica

1. O servidor atual possui um disco rígido com capacidade máxima operacional de 5.000 GB. Utilizando a equação do modelo ajustado, determine em qual dia (x) o servidor atingirá esse limite crítico.
2. Sabendo que o dataset monitorou até o dia $x = 10.000$:
 - o Quantos dias restam a partir do último dado coletado até o esgotamento total?
 - o Elaborar uma recomendação técnica para a equipe de gestão de TI, sugerindo um plano de ação (prazos para compra de novos discos, migração para nuvem ou políticas de retenção de logs).