Atividade de Iniciação Científica

- **Tema:** Classificação de entregas (correta ou atraso) por regressão logística
- **Área:** Análise e Desenvolvimento de Sistemas / Infraestrutura de TI
- **Dataset:** dados_logistica.csv (42 observações)

Problema

Uma transportadora deseja investigar se a antecedência com que um pedido é despachado pode ajudar a prever o cumprimento do prazo de entrega.

Para isso, disponibilizou o arquivo dados_logistica(1).csv, contendo 42 pedidos. Cada registro apresenta a identificação do pedido, a antecedência do despacho e o resultado observado da entrega.

A antecedência corresponde ao número de horas entre o despacho e o prazo final. Por exemplo, uma antecedência de 10 horas significa que o pedido foi despachado 10 horas antes do prazo previsto para sua entrega.

O objetivo é desenvolver um modelo de regressão logística binária para estimar a probabilidade de um pedido chegar na data correta e classificá-lo em uma das categorias:

$$y = \begin{cases} 0, & entrega\ com\ atraso \\ 1, & entrega\ na\ data\ correta \end{cases}$$

Os dados são didáticos e não representam necessariamente o funcionamento de uma transportadora real.

1. Compreender o problema

2. Identificar o tipo de tarefa

3. Identificar as variáveis e conhecer os dados

4. Visualizar os dados antes de ajustar o modelo

5. Ajustar a regressão logística

Inicialmente, utilize os 42 registros para realizar um ajuste didático e compreender o método.

Considere:

$$Z(x) = \beta_0 + \beta_1 . x$$

$$p(x) = P(Y = 1 \mid x) = \frac{1}{1 + e^{-Z(x)}}$$

a) otimizar o problema de forma a encontrar β_0 e β_1.

b) Apresentar os coeficientes estimados e escreva as funções $Z(x)$ e $p(x)$.

c) Interpretar o sinal de β_1: a probabilidade de entrega na data correta aumenta ou diminui com a antecedência?

d) Calcule as probabilidades para 5, 10, 15 e 20 horas de antecedência.

e) Para cada caso, informe também a probabilidade de atraso:

$$P(Y = 0 \mid x) = 1 - p(x).$$

6. Classificar os pedidos e construir o gráfico da função logística ajustada, utilizando o limiar que maximiza a acurácia. Determinar, pela inversão da função logística, a antecedência correspondente a esse limiar.

7. Construir a matriz de confusão

8. Calcular e interpretar as métricas

- Acurácia
- Previsão da classe positiva
- Sensibilidade ou Recall
- Especificidade
- F-Score 1